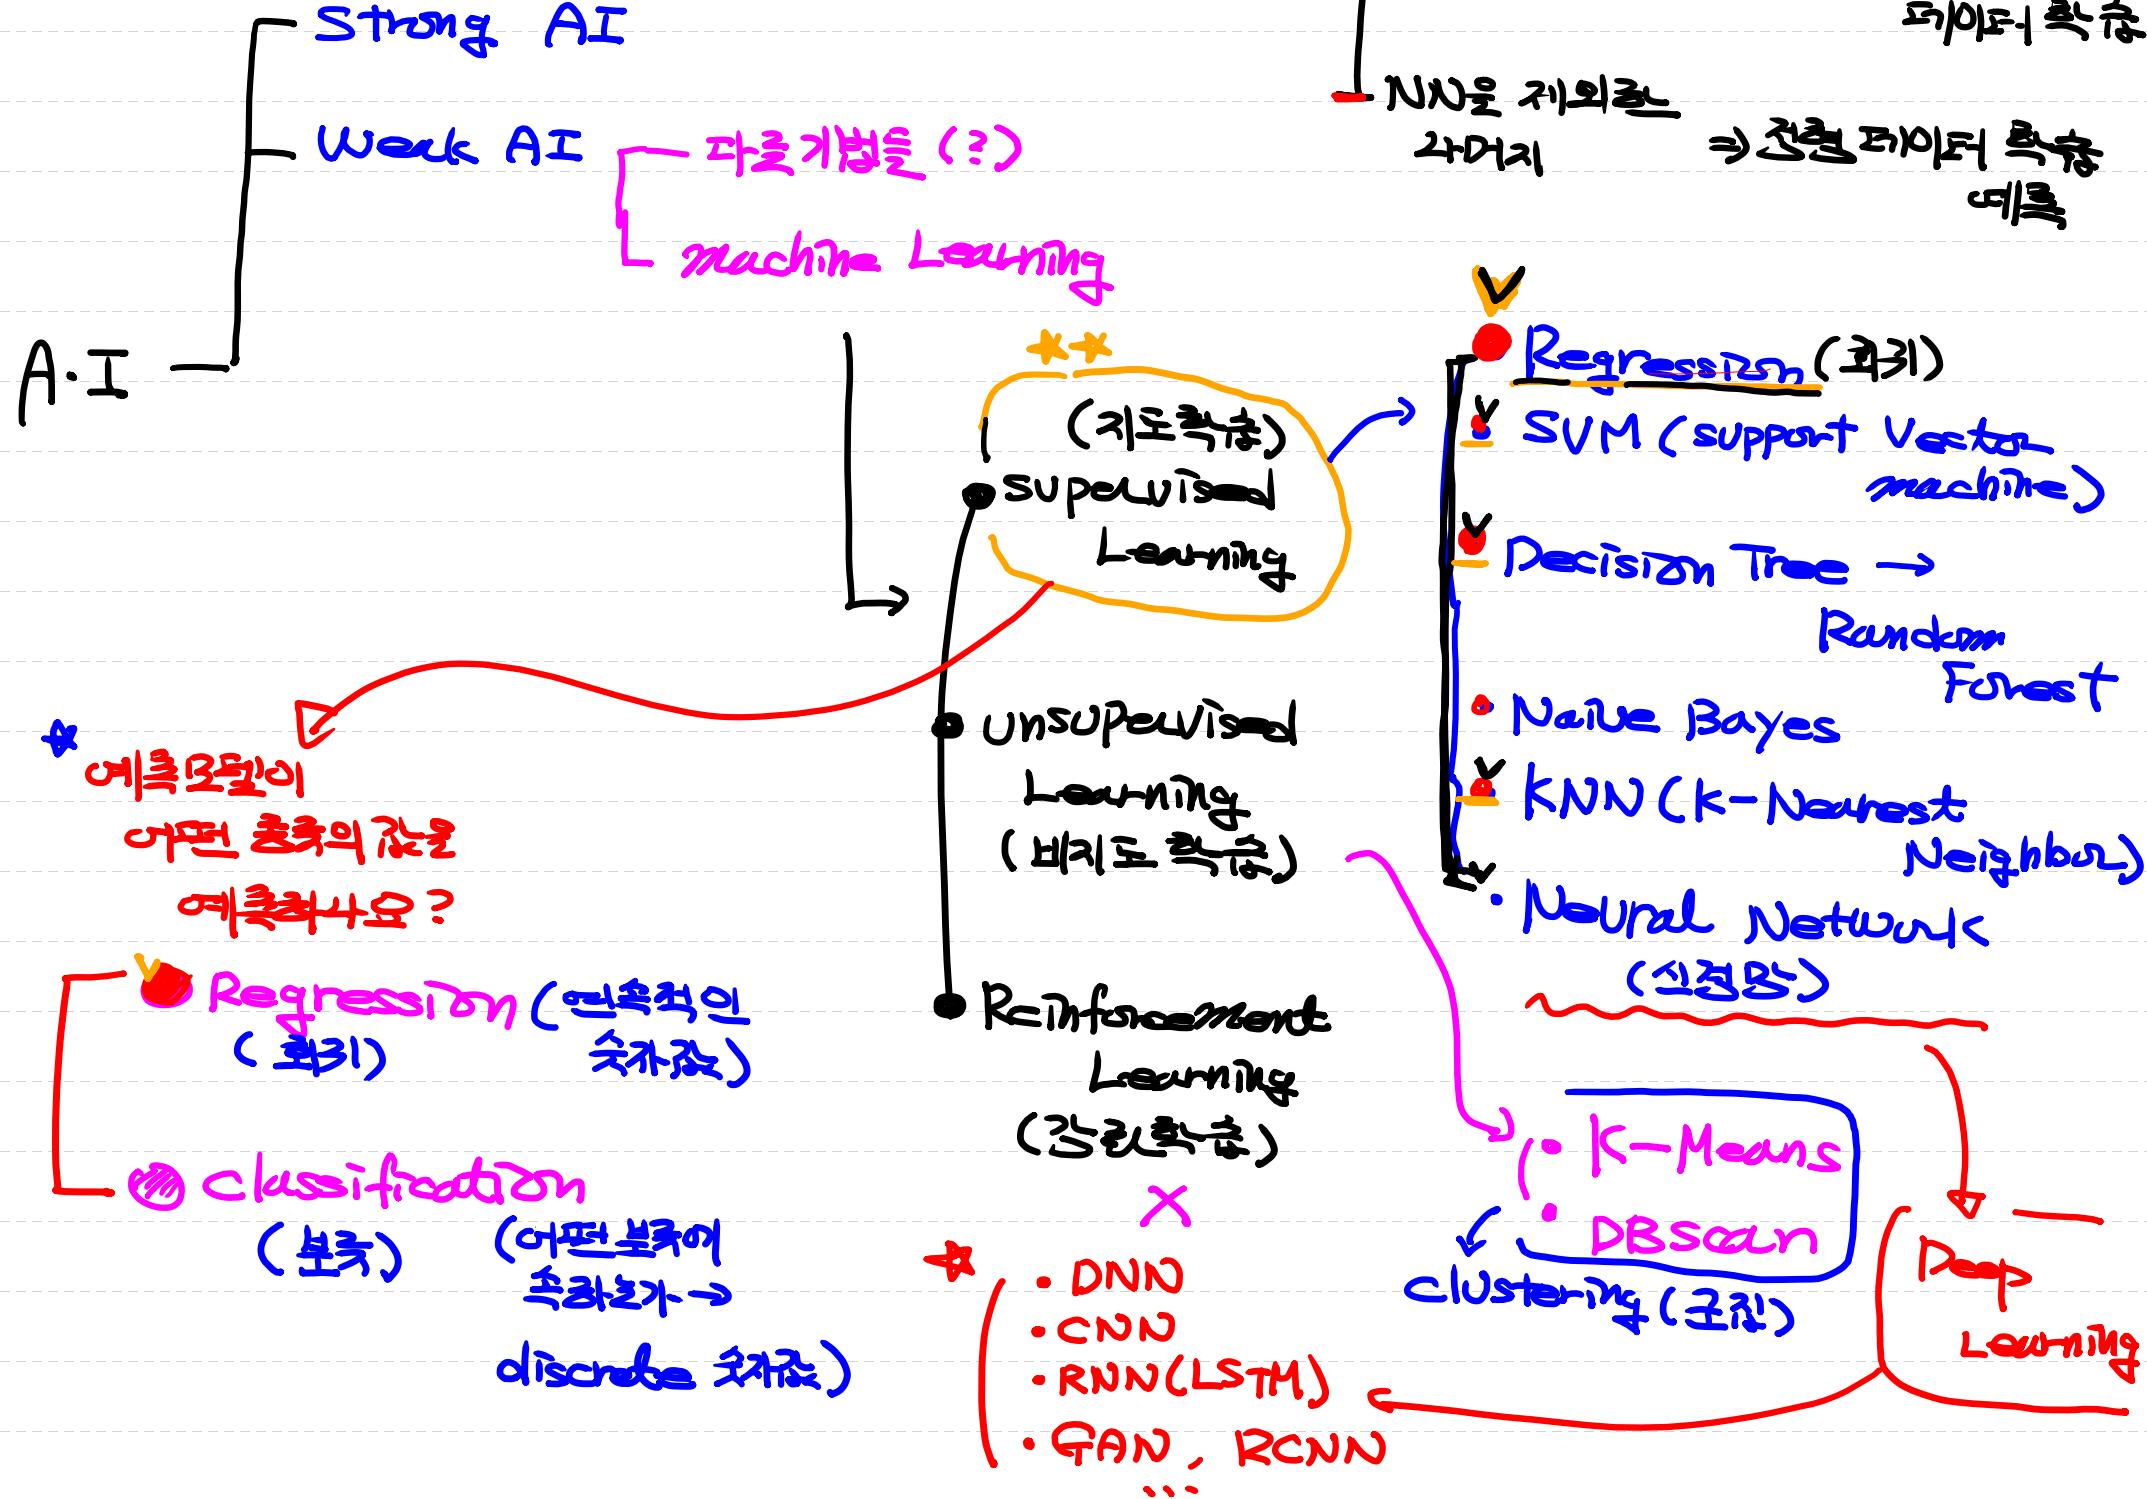


• 03/22



Regression (회귀) → ~~구조~~ ~로 돌아가요

프란시스 쿨리 (1805 ~ 1905) → Regression Toward of Mean
→ 데이터가 초기 모델의 주시킬 추세선에 수렴

찰스 디의 (총리기초) → 의자 개선을 목적으로 우량한 육성을 목적으로
서책적 출신 → 우생학 (의자를 개선하는 과학)
* 출생률은 사람을 차별화 경쟁력을 국가적 영향을 끌어 놓는다!
✓ 오 키가 커요 ✓ 오 키가 작아요
= =
자작 자작
 ↓
 키가 커요
 ↓
 키가 작아요

* Regression 회귀
 * 어떤 데이터 대체
 그 데이터에 영향을 주는 조건들의 평균적인 영향력을 이용해
 데이터에 따른 조건부 평균을 구하는 개념

아파트 평균가격 = $(140 \times 풍수) + (.350 \times 면적\text{m}^2) + (70 \times 층수) + \dots$

• 평균을 대표성을 가져요

여러 데이터를 가장 잘 표현하는.

* Regression Model

→ 어떤 데이터에 대해
그 값이 영향을 주는 조건들을 고려해가
그 데이터를 가장 잘 표현하는 품수.

독립변수가 1개인 경우

$$y = \beta_1 x + \beta_0$$

↑
결과변수
아파트가격

↑
독립변수
지역

→ 추정치와
실제값을 노려주기 위한 수식.

Classical
Linear
Regression
기본

$$y = ax + b$$

↑
기울기
↓
절편

→ 왜 이런 Regression Model을 만드나요?

- ① 현상과의 차이
- ② 조건의 영향력
- ③ 예측을 편리

• Regression Model

→ 여러가지 복잡한 조건들이나
평균을 간제로 구할 수 있도록 하는 효율적인 방법

조건들을 이용해 평균을 추구로 구하도록 해주는 기법.

"한가지 추적해야 좋겠"

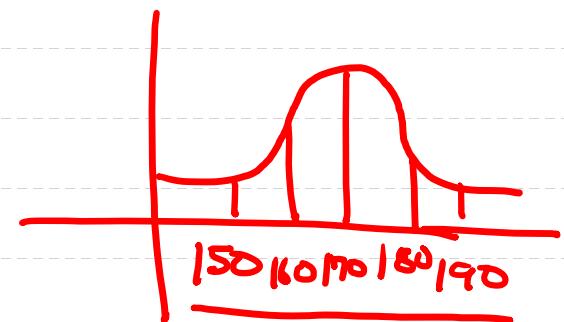
↳ 평균을 구할 때 추적해야 좋 사항이 regression에도 적용

- ① 우리에게 선의 능성이 기
- ② 우리에게 전제 조건의 염불

이 중 평균을
대통령으로 사용할 수 있는
경우는?



→
전체평균



* 회귀 모델 = 영향력 1 × 조건 1 + 영향력 2 × 조건 2 + 영향력 n × 조건 n

회귀계수 (regression coefficient)

? =

* 고전적 선형 회귀 모델
(Classical Linear Regression Model)

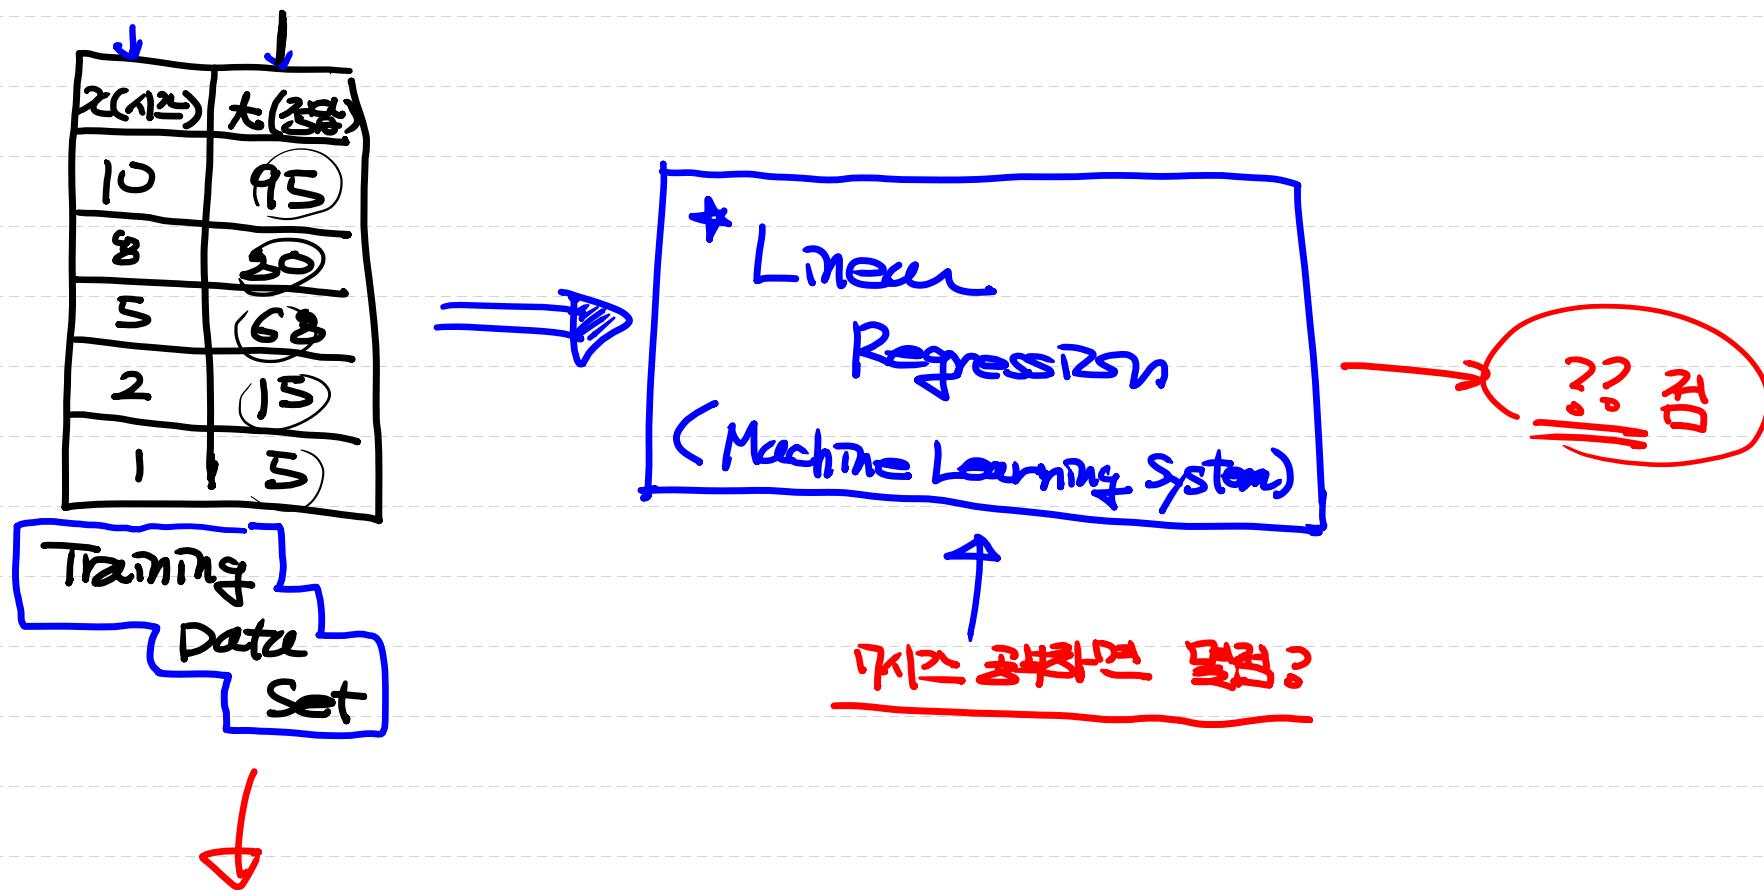
$$\hat{y} = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

일반적

• 단일 선형 회귀
(Simple Linear Regression)
→ 독립변수가 1개

• 다중 선형 회귀
(Multiple Linear Regression)
→ 독립변수가 2개 이상

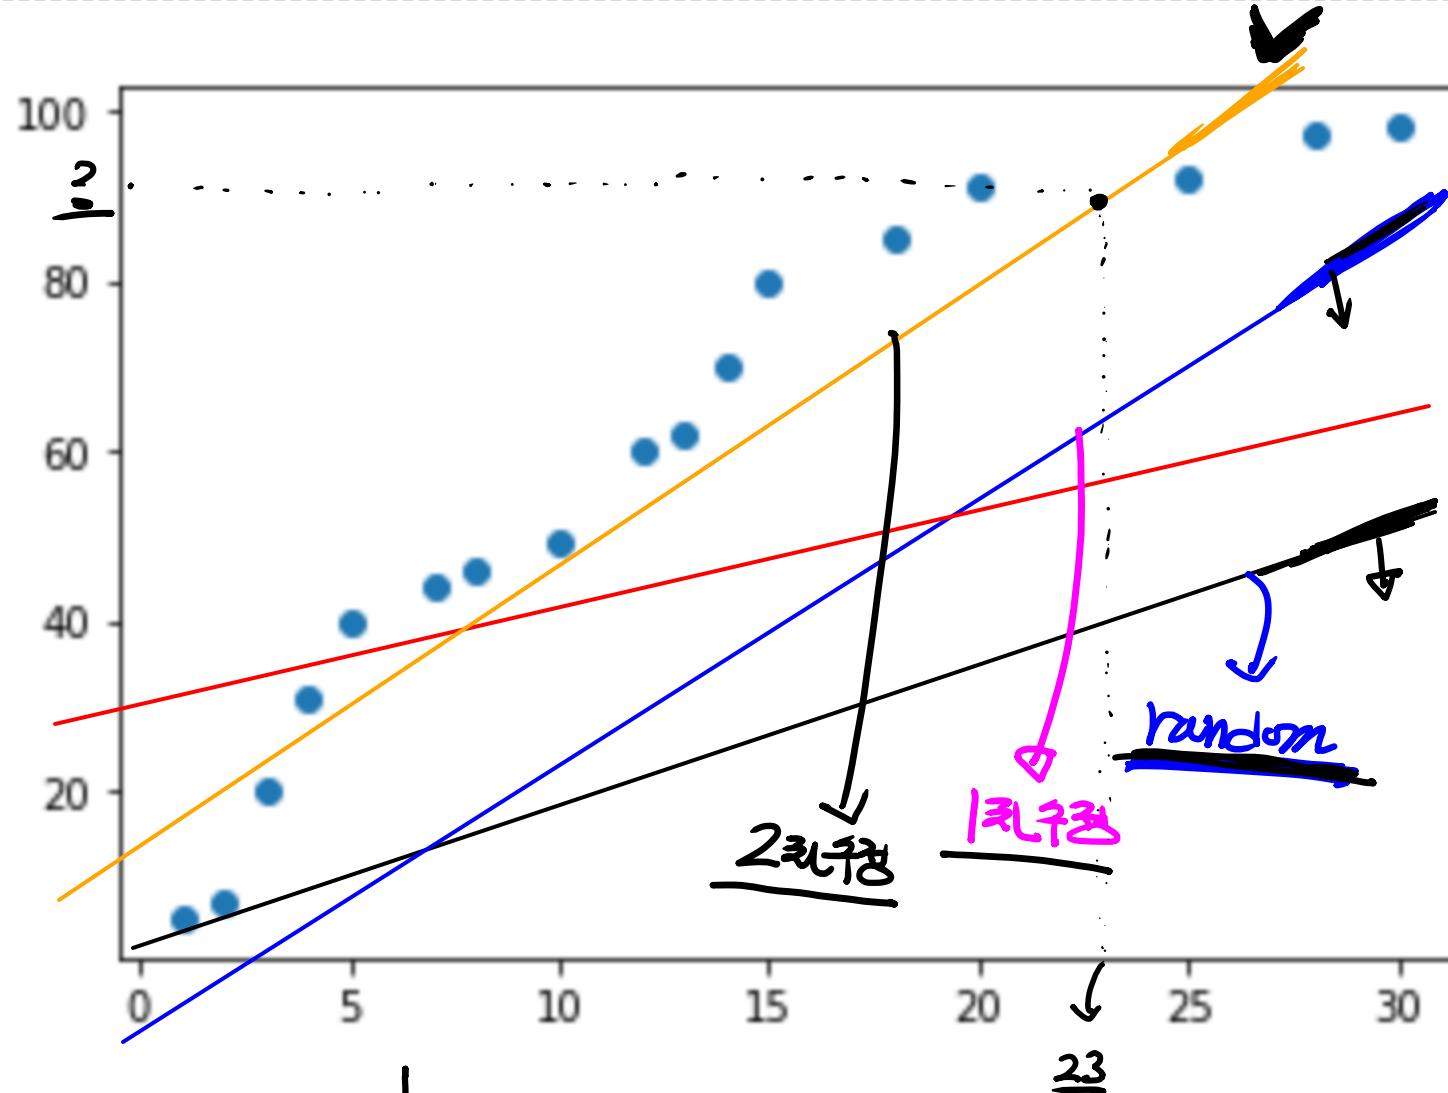
Machine Learning with Linear Regression



단순 선형 회귀(Simple Linear Regression)로 이 문제를

도식(그래프)으로 표현해 놓아요.

↳ scatter (산점도)



* 고전적 선형 회귀 모델
(Classical Linear Regression
model)

$$\hat{y} = \beta_0 + \sum_{i=1}^p \beta_i x_i \quad (\text{일반식})$$

↓ 독립변수 1개

$$\hat{y} = \beta_0 + \beta_1 x_1$$

$$\hat{y} = ax + b \quad (\text{직선})$$

? ? 어때요?

처음에는 a, b 값을 random

a와 b를 수정 → 조금 더 데이터를 잘 표현

a와 b를 수정 → 조금 더 직선을

직선

$$y = \underline{w}x + b$$

=====

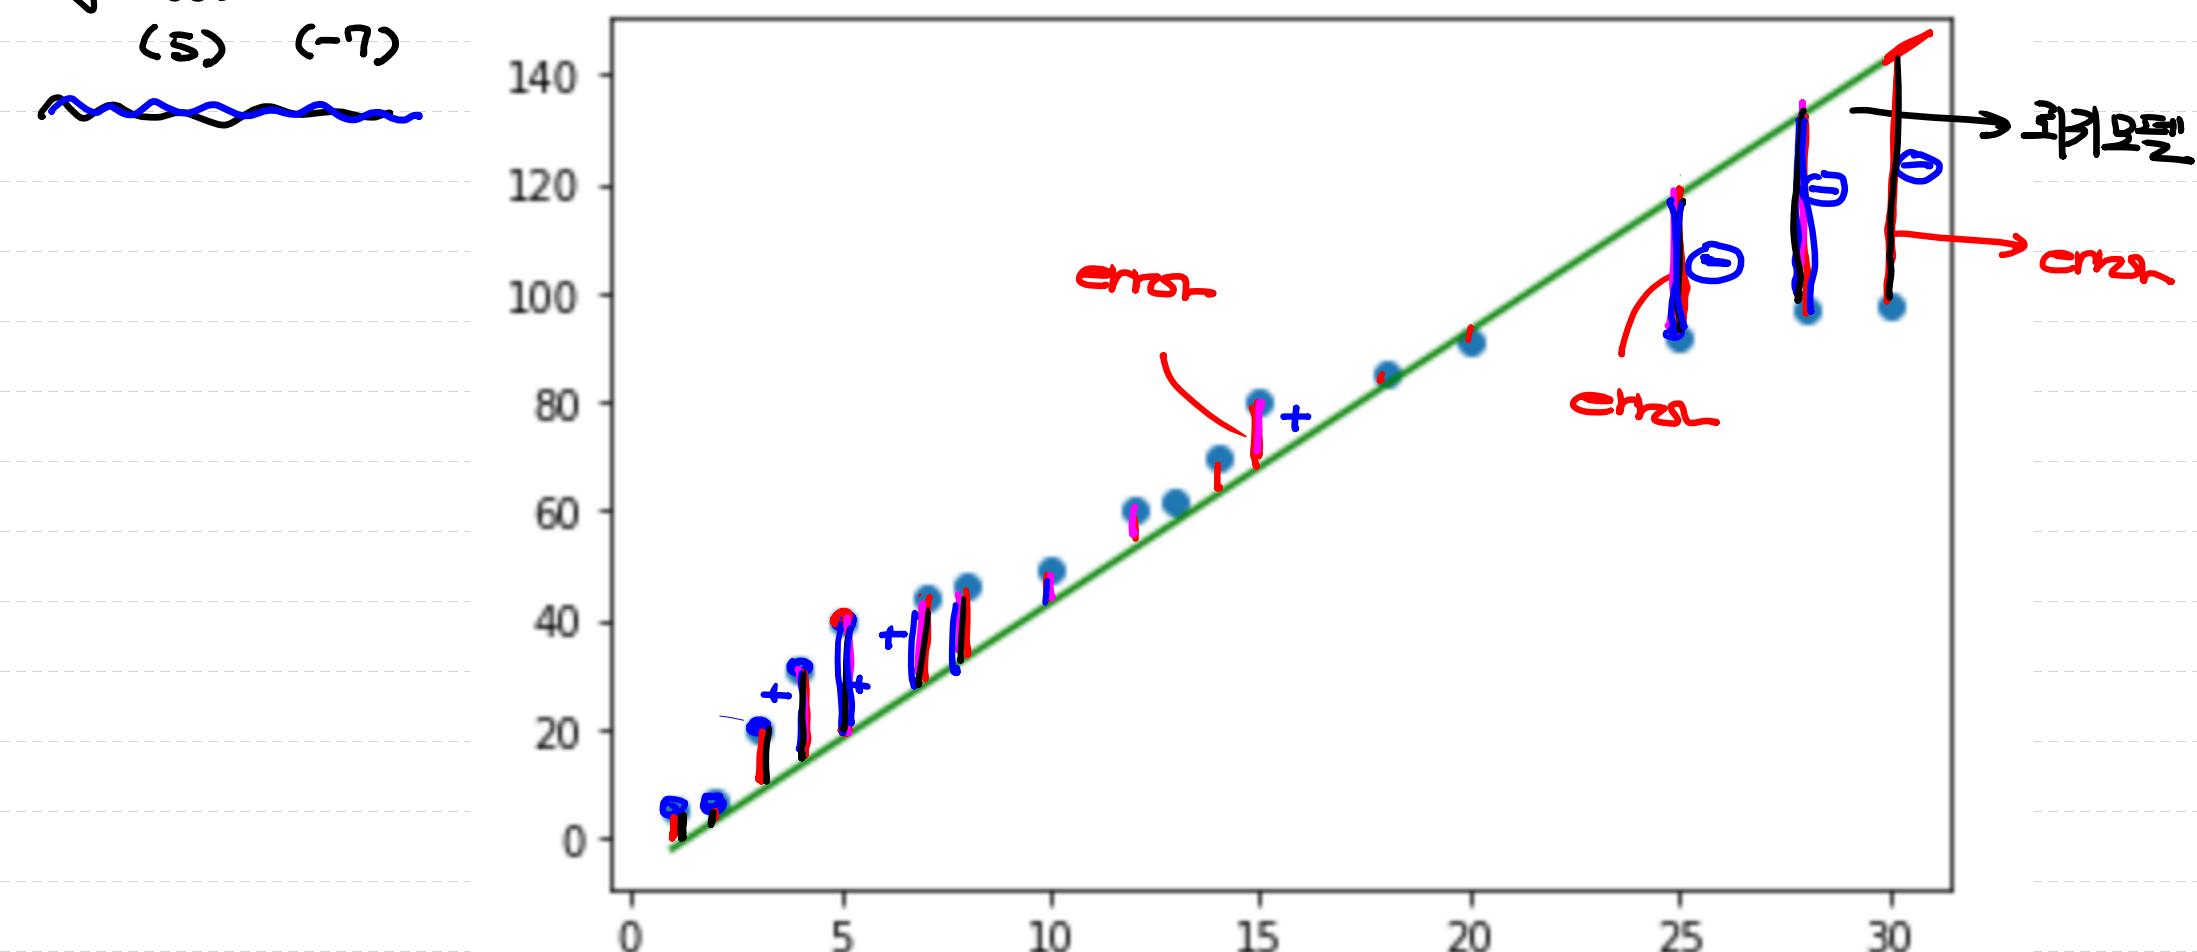
Weight
(가중치) bias
(바이어스)

잘아나가는
과정

"Learning" (학습)

$$y = w_2x + b$$

(5) (-7)



* 오차(error) vs 실제값(眞值, 大) 과 예측값(予)의 차이 → 주의주의 좋아요

 Error = $t - y$ = $t - (w_2x + b)$

오늘의 종이 문제 작아야 좋아요!! → 오늘도는 종이 여러개 → 하나의 숫자로 표기하고 싶어! → 한 줄

- 앗 그러면 각 error의 절대값의 합은 어때요?!
 - ▶ 허나의 문제이기는 해요. 하지만 우리는 다른 방법을 이용.

- 다음 방식으로 우리는 오류의 제곱의 평균을 이용.

↳ 제곱 → 오류가 대로 가중치를 줄 수 있어요.

⇒ 평균제곱오류 (MSE : Mean Squared Error)

↳ 즉으면 죽을 죽을 좋아요

↳ 평균제곱오류(MSE)를 가장 적게 만드는 w, b 를 찾는 문제로 생각할 수 있어요!

↳ * loss function (cost function)

* 손실함수 or 비용함수

이 함수를 찾는 방법을

“최소제곱법”이라고 해요 (Least squared Method)

f

* loss function = $\frac{(t_1 - y_1)^2 + (t_2 - y_2)^2 + (t_3 - y_3)^2 + \dots + (t_n - y_n)^2}{n}$

$y = wx + b$

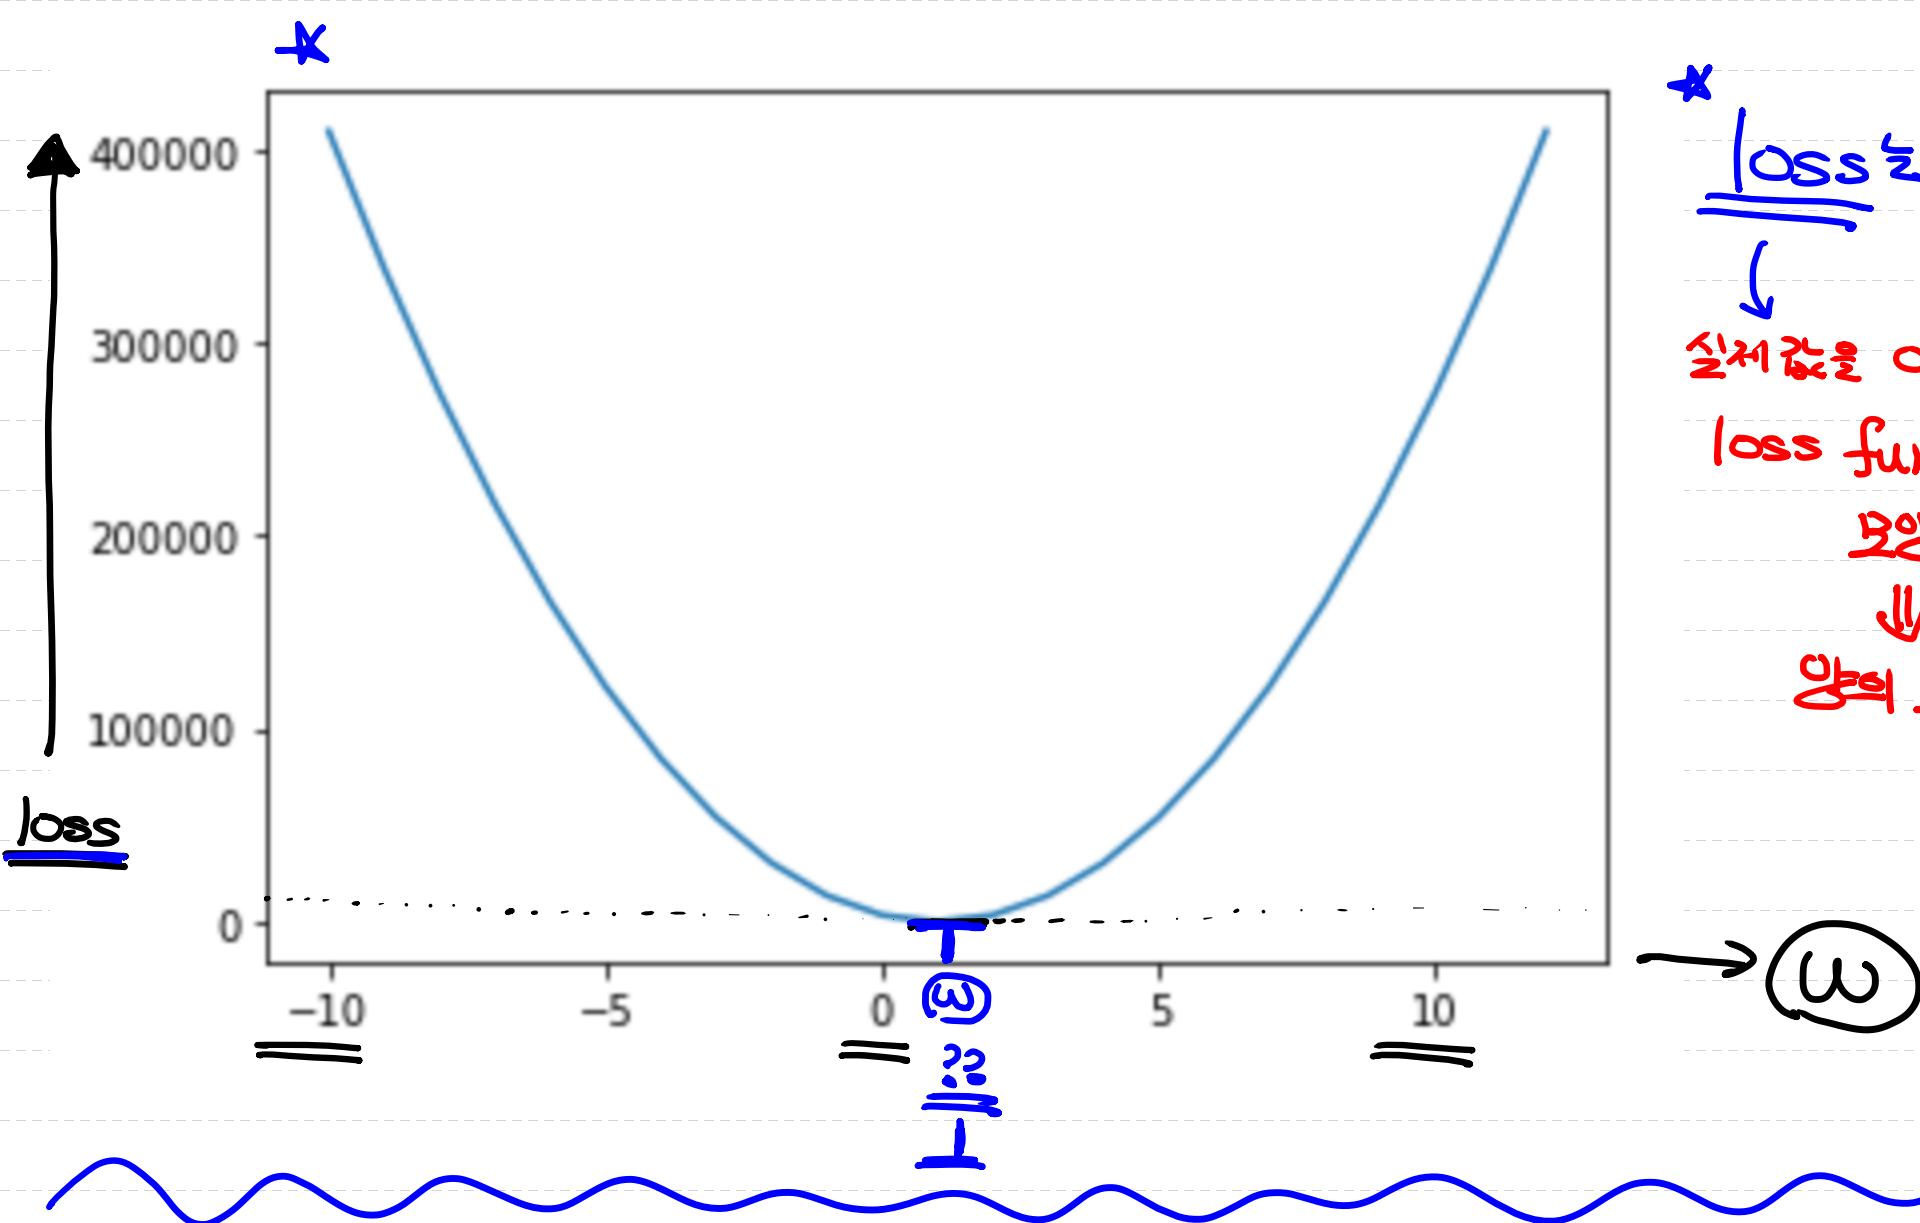
$$= \frac{(t_1 - (wx_1 + b))^2 + (t_2 - (wx_2 + b))^2 + \dots + (t_n - (wx_n + b))^2}{n}$$

$$= \frac{1}{n} \sum_{i=1}^n [t_i - (wx_i + b)]^2$$

* $E(w, b)$ = $\frac{1}{n} \sum_{i=1}^n [t_i - (wx_i + b)]^2 \Rightarrow \text{loss function}$

최소로 만드는
 w, b 를 찾는 거예요!!

* 보상을 좀
알아보아요!!



* loss는 w, b 의
함수
실제값을 이용해
loss function의
모양 확인!
↓
양의 조율

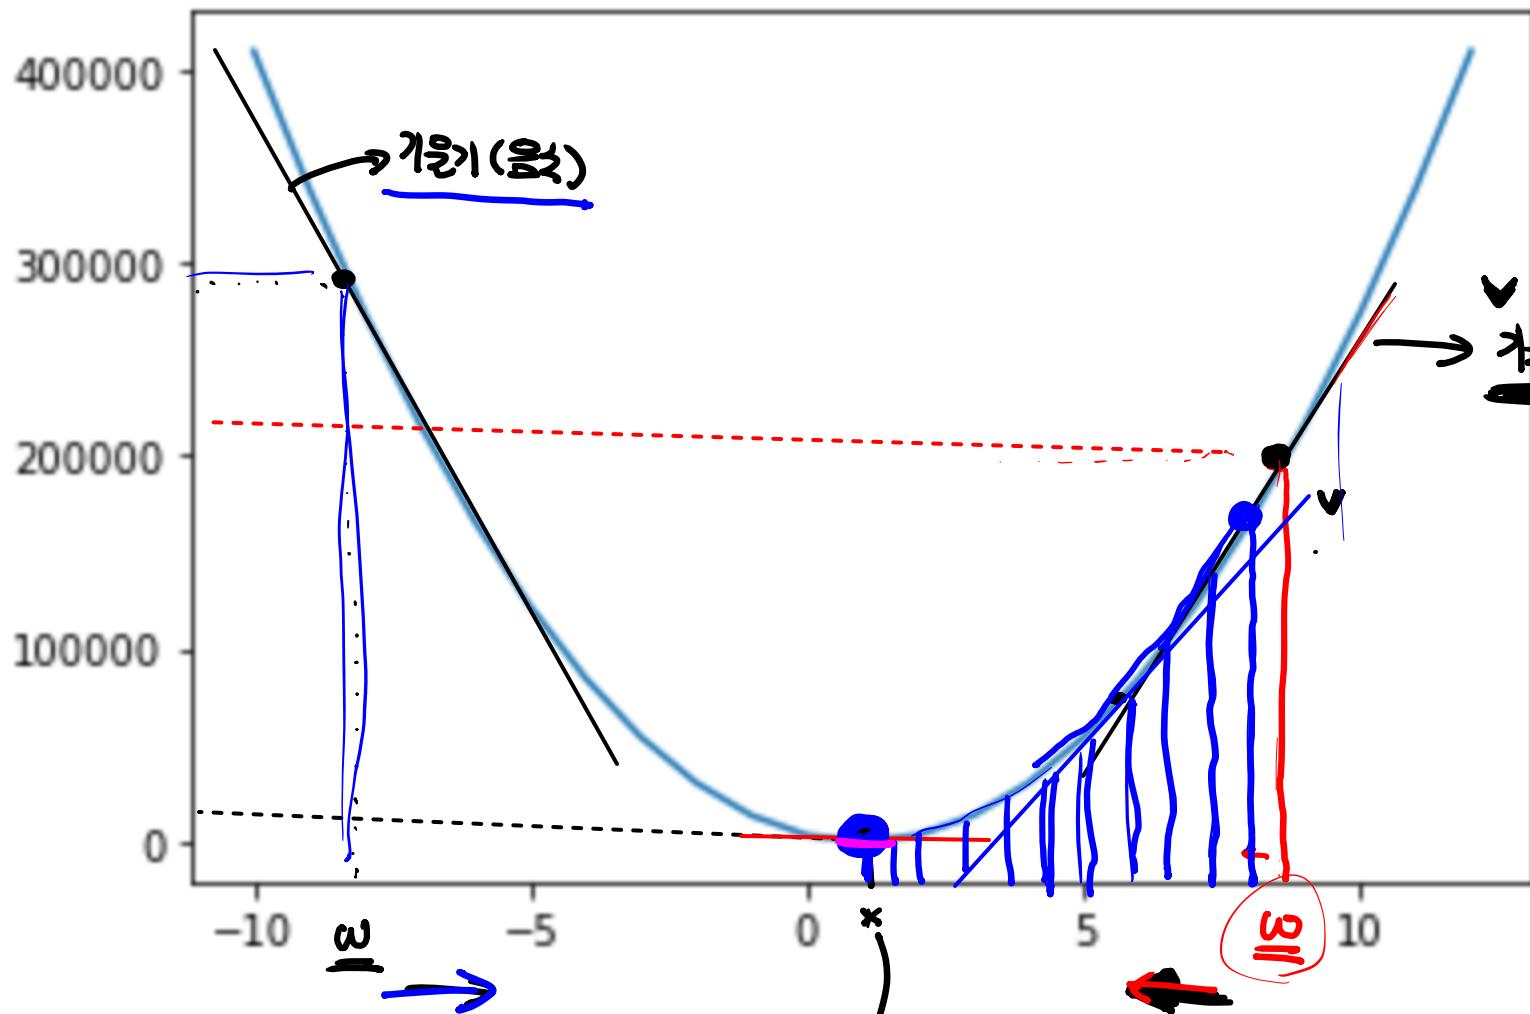
loss function의 값이 최소가 되게 하는 w 를

구하려면 어떻게 해야 하나요 ??

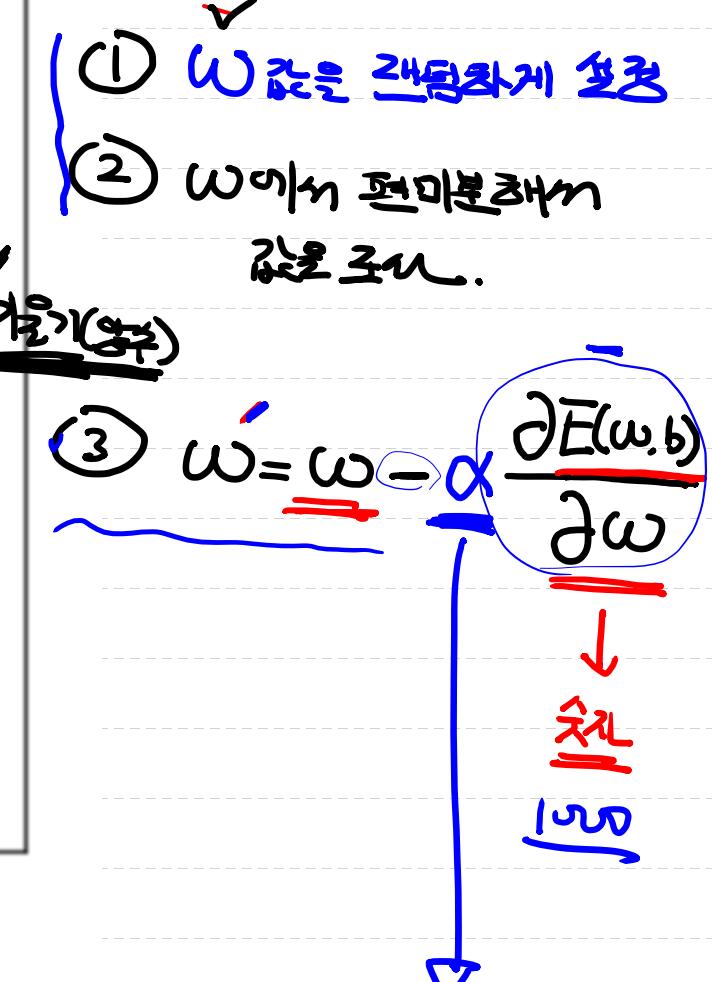
(경사하강법)

Gradient Descent Algorithm 이용

* gradient descent *



$$y = \underline{w}x + b$$



◎ 첫번째 보면,

독립변수가 1개인 "Simple Linear Regression"의 목표는

Training Data Set의 특성과 분포를 잘 나타내는 임의의 직선인

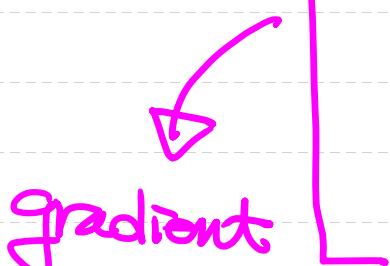
* $y = w_1x + b$ 를 구하고 그것이 결국 (w, b) 을 구하는게 목표.

→ MSE(평균제곱오차)를 이용한 loss function을 만드는데요

* loss function을 최소로 만드는 w, b 를 구하려고 해요!

w, b 를 구하기 위해 $E(w, b)$ 을 w, b 에 대해 편미분해요

편미분값(증선의 기울기) \times learning rate \Rightarrow 이 값을 w, b 에서
(즉 ∇E)
최소



Descent 알고리즘.

반복해서
 $\nabla E(w, b)$ 계산

최적의 w, b 찾아요!



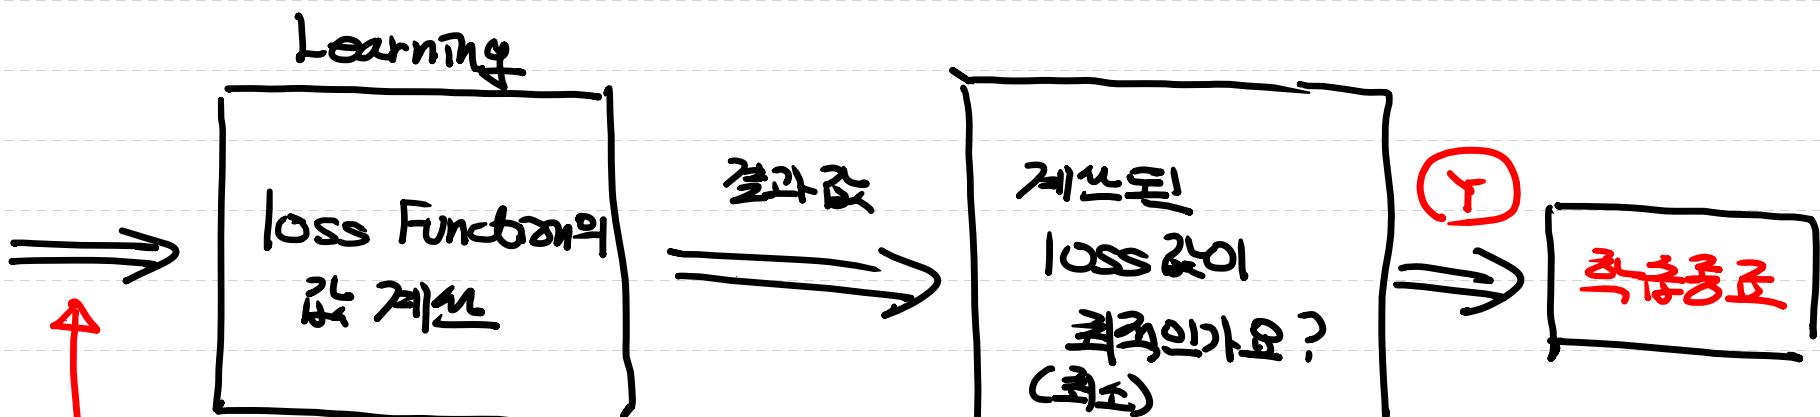
(Model) $y = w \cdot x + b$ \hookrightarrow w, b 초기값은 random

$$y = w \cdot x + b$$

(Loss Function)

$$E(w, b) = \frac{1}{n} \sum_{i=1}^n [t_i - (w \cdot x_i + b)]^2$$

시그(x)	성적(t)
1	1
2	10
5	30
8	70
10	90



* Training Data Set

Weight, bias Update

$$w' = w - \alpha \frac{\partial E(w, b)}{\partial w}, \quad b' = b - \alpha \frac{\partial E(w, b)}{\partial b}$$

